

RAPPORT D'ANALYSE EXPLORATOIRE DES DONNÉES

Jeu de données de commandes E-Commerce

Stage en Analyse de Données — DecodeLabs

Projet 2

Préparé par : Floratin DOGBO

Lomé, Togo

Août 2026

Résumé Exécutif

Ce rapport présente l'Analyse Exploratoire des Données (AED) réalisée pour le Projet 2 du stage en Analyse de Données chez DecodeLabs, portant sur un jeu de données de commandes e-commerce couvrant les commandes clients, le mix produits, la tarification, les méthodes de paiement et le statut de livraison.

L'analyse a combiné des statistiques descriptives, une détection des valeurs aberrantes (outliers) et une analyse de tendances par tableaux croisés dynamiques dans Excel, afin de répondre à quatre questions métier clés : comment se comportent les prix et la taille des commandes, comment évolue le volume de commandes dans le temps, si les codes promo influencent les dépenses, et comment se répartissent les statuts de commande et les méthodes de paiement. Une seconde couche d'analyse a traduit ces constats en indicateurs (KPI) de revenu et de livraison.

Le constat principal est un écart important entre le revenu potentiel et le revenu réalisé : sur un revenu total attendu de 1,26 M\$, seuls 242,6 K\$ (19,18 %) ont été réellement réalisés, en raison d'un faible taux de succès de livraison (19,25 %) et de volumes élevés de commandes annulées, retournées et en attente. Le rapport se termine par dix recommandations opérationnelles et marketing visant à réduire cet écart.

1. Introduction

Ce rapport couvre le Projet 2 du stage en Analyse de Données chez DecodeLabs, une Analyse Exploratoire des Données sur un jeu de données de commandes e-commerce contenant les commandes clients, les produits, la tarification, la méthode de paiement et le statut de commande.

2. Énoncé du Problème

L'objectif de cette analyse était de :

- Comprendre les tendances de prix sur l'ensemble des produits et commandes
- Analyser l'évolution des commandes dans le temps (mensuelle et annuelle)
- Déterminer si les codes promo influencent les dépenses des clients
- Examiner la répartition des statuts de commande et des méthodes de paiement
- Évaluer si les valeurs aberrantes des données sont des erreurs ou de véritables comportements clients

...et, in fin, transformer ces constats en enseignements exploitables par l'entreprise.

3. Aperçu du Jeu de Données

Le jeu de données comporte 1 200 commandes réparties sur 14 colonnes, regroupées par type avant l'analyse :

Type de colonne	Colonnes
Numérique	Quantity, UnitPrice, ItemsInCart, TotalPrice

Catégorielle	Product, PaymentMethod, OrderStatus, ReferralSource, CouponCode
Temps / Tendance	Date
Identifiant (non utilisé dans les stats)	OrderID, CustomerID, TrackingNumber, ShippingAddress

OrderID, CustomerID et TrackingNumber ont été exclus des statistiques car ils sont uniques pour chaque ligne. ShippingAddress était en grande partie une donnée de substitution (placeholder). PaymentMethod incluait le paiement en espèces (Cash) aux côtés des options numériques, cohérent avec un système de paiement à la livraison (Cash on Delivery).

4. Méthodologie

Les colonnes ont d'abord été triées par type, puis des statistiques descriptives (moyenne, médiane, écart-type, asymétrie, min, max, effectif) ont été calculées sur toutes les colonnes numériques dans Excel.

- Les valeurs aberrantes ont été vérifiées à l'aide de la méthode IQR et de boxplots
- Des tableaux croisés dynamiques ont été utilisés pour étudier les tendances mensuelles et annuelles des commandes (2023, 2024, et les mois disponibles de 2025)
- Des catégories comme OrderStatus, PaymentMethod et CouponCode ont été comparées au nombre de commandes et à la valeur moyenne de commande
- Certains mois spécifiques (ex. juin 2024) ont été décomposés davantage par produit, usage de coupon et source de référence

5. Statistiques Descriptives

Les statistiques descriptives complètes ont été calculées dans Excel pour les quatre variables numériques (Quantity, UnitPrice, ItemsInCart, TotalPrice) sur l'ensemble des 1 200 commandes :

Statistique	Quantity	UnitPrice	ItemsInCart	TotalPrice
Moyenne	2,9458	356,41	5,485	1 053,97
Erreur Standard	0,0406	5,692	0,0659	23,667
Médiane	3	364,21	5	823,62
Mode	1	127,18	5	635,90
Écart-type	1,4076	197,18	2,282	819,86
Variance d'échantillon	1,9812	38 878,83	5,207	672 164,78

Kurtosis	-1,2946	-1,1910	-0,7086	-0,0404
Asymétrie (Skewness)	0,0279	-0,0265	0,0009	0,8914
Étendue	4	688,54	9	3 445,01
Minimum	1	11,39	1	11,39
Maximum	5	699,93	10	3 456,40
Somme	3 535	427 695,30	6 582	1 264 761,96
Effectif	1 200	1 200	1 200	1 200

Interprétation

- Quantity, UnitPrice et ItemsInCart présentent toutes une asymétrie proche de zéro (0,028, -0,027 et 0,0009 respectivement) et un kurtosis négatif, confirmant des distributions quasi symétriques, légèrement « plus plates que la normale » et sans queues épaisses cohérent avec un comportement d'achat équilibré et régulier.
- TotalPrice fait exception : son asymétrie de 0,89 confirme une asymétrie positive (à droite) une longue traîne de commandes à forte valeur tire la moyenne (1 053,97 \$) bien au-dessus de la médiane (823,62 \$). C'est attendu, puisque TotalPrice résulte du produit de Quantity et UnitPrice plutôt que d'être distribué indépendamment.
- L'écart-type relatif à la moyenne est le plus élevé pour TotalPrice ($\approx 78\%$ de la moyenne) et UnitPrice ($\approx 55\%$ de la moyenne), reflétant une réelle diversité de prix dans le catalogue, tandis que Quantity et ItemsInCart varient beaucoup moins (cohérent avec des tailles de panier habituelles).

Forme de la distribution de TotalPrice — asymétrie positive




Figure 1 — Forme de la distribution de TotalPrice (courbe illustrative dérivée de la moyenne, de la médiane et de l'asymétrie rapportées), montrant l'asymétrie à droite et la borne des outliers.

6. Analyse des Valeurs Aberrantes (Méthode IQR)

Les bornes des valeurs aberrantes ont été calculées pour chaque variable numérique selon la règle $1,5 \times \text{IQR}$ (Borne Inf. = $Q1 - 1,5 \times \text{IQR}$, Borne Sup. = $Q3 + 1,5 \times \text{IQR}$) :

Variable	Q1	Q3	IQR	Borne Inf.	Borne Sup.	Max Observé	Outliers Détectés
Quantity	2	4	2	-1	7	5	Aucun
UnitPrice	185,63	521,91	336,28	-318,80	1 026,33	699,93	Aucun
ItemsInCart	4	7	3	-1	12	10	Aucun
TotalPrice	410,52	1 579,73	1 169,21	-1 343,29	3 333,53	3 456,40	8 commandes

Interprétation

- Pour Quantity, UnitPrice et ItemsInCart, la valeur maximale observée dans le jeu de données reste inférieure à la borne supérieure calculée : ces variables ne contiennent donc aucune valeur aberrante statistique — ce qui confirme que la taille des commandes et les prix se comportent normalement.
- TotalPrice est la seule variable où la valeur maximale observée (3 456,40) dépasse la borne supérieure (3 333,53). Cela signale 8 commandes comme valeurs aberrantes statistiques — les mêmes 8 identifiées dans la section Résultats, combinant toutes une Quantity de 5 avec un produit à coût élevé (Tablette, Moniteur, Ordinateur portable ou Imprimante). Comme elles s'expliquent par une cause claire et cohérente plutôt que par du bruit aléatoire, elles sont considérées comme de véritables commandes en gros et conservées dans l'analyse plutôt que retirées comme erreurs de données.

7. Résultats

- Les prix et la taille des commandes sont plutôt équilibrés. UnitPrice, Quantity et ItemsInCart sont tous proches de la symétrie, sans asymétrie inhabituelle.
- TotalPrice est asymétrique, mais les outliers sont réels, pas des erreurs. 8 commandes ont été signalées, toutes avec une Quantity de 5 et des produits à coût élevé (Tablette, Moniteur, Ordinateur portable, Imprimante) de véritables commandes en gros, pas des erreurs.
- Le revenu a chuté entre 2023 et 2024 principalement à cause d'un nombre de commandes plus faible, pas de commandes plus petites. La valeur moyenne de commande a à peine changé ($\approx 1\,084 \$$ vs $\approx 1\,046 \$$), mais le nombre de commandes est passé de 510 à 459.
- Il existe un pic de ventes récurrent en milieu d'année, mais son timing varie. 2023 a culminé en mai, 2024 en juin, et 2025 (jusqu'en juin) suit la même tendance.

5. Le pic de juin 2024 n'était pas lié aux coupons. Les commandes SANS COUPON étaient elles aussi élevées ce mois-là. Phone et Printer étaient les meilleures ventes, ce qui pointe vers une demande organique.
6. Les commandes annulées ont la valeur moyenne la plus élevée (1 106) ; les commandes retournées la plus faible (985). Les commandes les plus susceptibles d'échouer comptent parmi les plus valorisées.
7. Phone sous-performe sur tous les plans le plus faible nombre de commandes, le plus faible volume vendu, le plus faible revenu, et la plus faible valeur moyenne de commande de tous les produits.
8. Le statut de commande et la méthode de paiement sont répartis de façon homogène, sans groupe dominant.
9. L'analyse de corrélation a montré que Quantity et Unit Price sont fortement liés (0,79) les clients qui achètent des produits plus chers ont aussi tendance à en acheter davantage, plutôt que d'en acheter moins à cause du prix. Cela suggère que le prix seul ne décourage pas les achats en gros, ce qui est utile à savoir avant toute décision de tarification.

8. Résultats Clés : Synthèse de l'Impact Business

Au-delà des statistiques descriptives, le jeu de données a été traduit en indicateurs (KPI) de revenu et de livraison pour évaluer la performance globale de l'entreprise :

1. L'entreprise a généré un Revenu Total Attendu de 1,26 M\$, mais seuls 242,6 K\$ ont été réalisés à partir des commandes livrées avec succès, indiquant un écart important entre revenu attendu et revenu réel.
2. Sur 1 200 commandes au total, seules 231 ont été livrées, soit un faible Taux de Succès de Livraison de 19,25 %.
3. Le Taux de Réalisation du Revenu était de 19,18 %, montrant qu'une grande partie du revenu potentiel a été perdue à cause des commandes annulées, retournées, en attente ou non livrées.
4. L'entreprise a enregistré de fortes inefficacités opérationnelles, avec 250 commandes annulées, 247 commandes retournées et 237 commandes en attente.
5. Les clients ont ajouté un total de 6 582 articles au panier, avec une moyenne de 5,49 articles par commande, traduisant un fort intérêt et engagement client.
6. Malgré cette forte activité de panier, le Taux de Conversion du Panier était de 53,71 %, suggérant que près de la moitié des articles ajoutés au panier n'ont pas été convertis en achats finalisés.
7. Le revenu moyen par commande livrée était de 1 050,22 \$, indiquant que les commandes menées à bien génèrent une valeur relativement élevée.
8. Laptop a été identifié comme le produit le plus livré, ce qui en fait la catégorie de produit la plus performante en matière de livraison réussie.
9. Instagram est ressorti comme la source de référence la plus fréquemment utilisée, traduisant une forte acquisition client via les réseaux sociaux.
10. Cependant, Email a généré le revenu réel le plus élevé, suggérant que l'email marketing a attiré des clients plus rentables ou avec un meilleur taux de conversion.

11. Le code promo « FREESHIP » a enregistré l'utilisation la plus élevée parmi les clients, soulignant la forte influence des incitations à la livraison sur les décisions d'achat.
12. L'année 2024 a généré le revenu le plus élevé, indiquant une performance commerciale plus forte durant cette période.




Figure 2 — Répartition des statuts de commande sur les 1 200 commandes. Seulement 231 commandes (19,25 %) ont été livrées.




Figure 3 — Revenu attendu (1,26 M\$) vs. revenu réellement réalisé sur les commandes livrées (242,6 K\$) — un Taux de Réalisation du Revenu de 19,18 %.




Figure 4 — Taux de conversion opérationnels clés : Conversion du panier, Succès de livraison, et Réalisation du revenu.

9. Recommandations

1. Améliorer les processus de livraison et de logistique afin de réduire le nombre élevé de commandes annulées, retournées et en attente.
2. Investiguer les causes profondes des livraisons échouées et des retours produits pour améliorer la satisfaction client et la réalisation du revenu.
3. Renforcer la gestion des stocks et les systèmes de suivi des commandes afin de minimiser les délais opérationnels et les livraisons incomplètes.
4. Augmenter l'investissement dans les campagnes d'Email Marketing, ce canal ayant généré le revenu réel le plus élevé malgré un trafic plus important via Instagram.
5. Continuer à exploiter Instagram pour l'acquisition client, tout en optimisant les stratégies de conversion pour transformer le trafic en achats finalisés.
6. Mettre en place des stratégies de relance de panier abandonné (emails de rappel, remises ciblées, offres à durée limitée) pour améliorer le taux de conversion du panier.
7. Développer la promotion et la disponibilité des produits les plus performants comme les Laptops, qui ont significativement contribué aux livraisons réussies.
8. Continuer à proposer des incitations liées à la livraison comme le code promo FREESHIP, les clients y ayant bien répondu.
9. Suivre régulièrement les KPI de performance de livraison Taux de Succès de Livraison, Taux de Réalisation du Revenu et Taux de Conversion du Panier pour mesurer les améliorations opérationnelles dans le temps.

10. Mettre en place une collecte de retours clients pour les commandes retournées et annulées afin d'identifier les problèmes récurrents de service ou de produit.

10. Conclusion

Cette analyse exploratoire montre que la tarification et le comportement d'achat sous-jacents du jeu de données e-commerce sont sains et prévisibles : les prix et la taille des commandes sont équilibrés, les outliers liés aux commandes en gros sont réels, et le prix ne semble pas décourager les achats plus importants. La principale faiblesse est opérationnelle : seule environ une commande sur cinq est réellement livrée, et c'est cet écart de livraison et non une faible demande qui sépare 1,26 M\$ de revenu potentiel des 242,6 K\$ réellement réalisés.

Comblar cet écart dépend moins de la génération de trafic ou d'intérêt supplémentaire (l'activité du panier et le trafic de référence sont déjà solides) que de la fiabilisation de la livraison, de la réduction des annulations et des retours, et de la conversion des canaux marketing déjà performants : l'email en particulier en une part plus importante de commandes finalisées. Les recommandations ci-dessus offrent une feuille de route de départ pour cette amélioration opérationnelle.